Cyprus University of Technology

Department of Electrical Engineering & Computer Science and Engineering

CSE_528: Deep Learning II

MSc Group Project

Efstathiou Panayiota, Hadjiandreou Kyriakos, Kestoras Stilianos, Kerkidou Demetra, Younes Judy

Limassol, May 2026

Table of Contents

1. Introduction 2
2. Dataset and Experimental Setup 2
2.1 Dataset 2
2.2 Μοντέλο και Υποδομή Εκτέλεσης 3
2.3 Πρωτόκολλο Αξιολόγησης και Αβεβαιότητα 3
2.4 Δομημένη Έξοδος 3
3. Model, JSON Validation, and Decision Mechanisms 4
3.1 Παραγωγή Δομημένης Εξόδου από το Μοντέλο 4
3.2 JSON Validation και Safe Fallback 4
3.3 Decision Mechanisms 5
3.4 Μηχανισμός Λήψης Τελικής Απόφασης 6
3.5 Σχέση με Αβεβαιότητα και Ασφάλεια 6
4. Results and Coverage–Risk Analysis 6
5. Robustness and Mitigation 8
5.1 Στόχος του Robustness Evaluation 8
5.2 Αποτελέσματα πριν από το Mitigation 8
5.3 Mitigation μέσω Κανονικοποίησης Κειμένου 9
5.4 Στρατηγική Ασφαλούς Χρήσης 10
5.5 Περιορισμοί και Μελλοντικές Βελτιώσεις 11
6. Failure Analysis, Ethics, and Conclusion 11
6.1 Failure Analysis 11
6.2 Ethics 12
6.3 Conclusion 12
References 13

1. Introduction

Τα τελευταία χρόνια, τα μεγάλα γλωσσικά μοντέλα (Large Language Models - LLMs) έχουν εξελιχθεί σε ισχυρά εργαλεία για την κατανόηση, επεξεργασία και παραγωγή φυσικής γλώσσας, επιτυγχάνοντας υψηλές επιδόσεις σε ένα ευρύ φάσμα εφαρμογών. Ένας σημαντικός τομέας αξιοποίησής τους είναι το moderation περιεχομένου (content moderation), όπου η αυτόματη ανίχνευση τοξικού ή επιβλαβούς λόγου αποτελεί κρίσιμο ζήτημα για την ασφάλεια των online πλατφορμών.

Οι παραδοσιακές προσεγγίσεις βασίζονται κυρίως σε discriminative μοντέλα, τα οποία εκπαιδεύονται σε επισημασμένα δεδομένα και παράγουν απευθείας μια κατηγορία. Αντίθετα, τα generative LLMs εισάγουν μια εναλλακτική προσέγγιση, όπου το μοντέλο μπορεί να λειτουργήσει ως “κριτής”, αξιολογώντας την τοξικότητα ενός κειμένου και παράγοντας όχι μόνο την τελική απόφαση αλλά και συνοδευτικές πληροφορίες, όπως αιτιολόγηση και εκτίμηση εμπιστοσύνης. Η απόφαση επιστρέφεται σε δομημένη μορφή JSON, ενισχύοντας τη διαφάνεια και επιτρέποντας πιο ευέλικτη διαχείριση αβεβαιότητας.

Η παρούσα εργασία μελετά τη χρήση ενός μικρού generative μοντέλου για την ανίχνευση τοξικότητας, δίνοντας έμφαση στην αξιοπιστία της εξόδου και στη διαχείριση αβέβαιων περιπτώσεων. Ιδιαίτερο ενδιαφέρον παρουσιάζει η δυνατότητα του συστήματος να αποφεύγει λανθασμένες αποφάσεις μέσω της επιλογής DEFER (abstention), οδηγώντας σε έναν συμβιβασμό μεταξύ της κάλυψης των προβλέψεων και του σφάλματος.

Για τη διερεύνηση των παραπάνω, εξετάζονται διαφορετικές στρατηγικές εξαγωγής αποφάσεων από το μοντέλο (Direct Generation, Log-likelihood Scoring, Self-Consistency) και συγκρίνεται η συμπεριφορά τους ως προς την ακρίβεια, τη σταθερότητα και το υπολογιστικό κόστος. Παράλληλα, αξιολογείται η ανθεκτικότητα του συστήματος σε μετασχηματισμούς εισόδου που προσομοιώνουν προσπάθειες αποφυγής moderation (evasion attacks), καθώς και η αποτελεσματικότητα απλών τεχνικών προεπεξεργασίας. Για την αντιμετώπιση αυτών των φαινομένων εφαρμόζεται μια απλή στρατηγική κανονικοποίησης εισόδου, χωρίς εκπαίδευση του μοντέλου.

Συνολικά, στόχος της εργασίας είναι να αναδείξει τις δυνατότητες αλλά και τους περιορισμούς των μικρών generative LLMs ως συστημάτων moderation, εστιάζοντας σε ζητήματα αξιοπιστίας, διαχείρισης αβεβαιότητας και ανθεκτικότητας.

2. Dataset and Experimental Setup

2.1 Dataset

Για την αξιολόγηση του συστήματος χρησιμοποιήθηκε το dataset Civil Comments, ένα ευρέως χρησιμοποιούμενο σύνολο δεδομένων για την ανίχνευση τοξικότητας σε online σχόλια. Σύμφωνα με τις απαιτήσεις της εργασίας, τα δεδομένα αξιοποιήθηκαν αποκλειστικά για αξιολόγηση και για τον καθορισμό πολιτικών απόφασης, χωρίς να πραγματοποιηθεί καμία διαδικασία εκπαίδευσης ή fine-tuning. Από το αρχικό dataset επιλέχθηκε ένα ισορροπημένο υποσύνολο 5.000 δειγμάτων, προκειμένου να εξασφαλιστεί δίκαιη σύγκριση μεταξύ των

διαφορετικών μεθόδων. Η κατανομή των κλάσεων είναι ισομερής, με 2.500 δείγματα να ανήκουν στην κατηγορία TOXIC και 2.500 στην κατηγορία NON_TOXIC. Το σύνολο δεδομένων χωρίστηκε σε validation και test σύνολα. Συγκεκριμένα, το validation set αποτελείται από 1.000 δείγματα (500 TOXIC και 500 NON_TOXIC), ενώ το test set περιλαμβάνει 4.000 δείγματα (2.000 TOXIC και 2.000 NON_TOXIC).

Η χρήση ισορροπημένου dataset επιτρέπει αξιόπιστη σύγκριση των μεθόδων, αποφεύγοντας φαινόμενα μεροληψίας λόγω ανισορροπίας κλάσεων. Για την αναπαραγωγιμότητα των πειραμάτων χρησιμοποιήθηκε σταθερό seed = 42.

2.2 Μοντέλο και Υποδομή Εκτέλεσης

Ως βασικό μοντέλο χρησιμοποιήθηκε το Gemma-2-2B-Instruct, ένα μικρό generative LLM κατάλληλο για εκτέλεση σε περιορισμένους υπολογιστικούς πόρους. Για την αποδοτική λειτουργία του μοντέλου εφαρμόστηκε 4-bit quantization (NF4), επιτρέποντας τη χρήση του σε περιβάλλοντα με περιορισμένη μνήμη. Η υλοποίηση βασίστηκε στη βιβλιοθήκη HuggingFace Transformers, ενώ το μοντέλο φορτώθηκε με χρήση τεχνικών βελτιστοποίησης μνήμης και υπολογισμών. Για τη μέθοδο Direct Generation χρησιμοποιήθηκε deterministic decoding (temperature = 0), ώστε να εξασφαλιστεί σταθερότητα στα αποτελέσματα.

Οι βασικές παράμετροι εκτέλεσης περιλαμβάνουν μέγιστο μήκος εισόδου 2048 tokens και μέγιστο αριθμό παραγόμενων tokens ίσο με 120. Η απόδοση του συστήματος αξιολογήθηκε και ως προς το υπολογιστικό κόστος, μέσω μετρήσεων latency και ρυθμού παραγωγής tokens. Το validation set αποτελείται από 1.000 δείγματα, ενώ η τελική σύγκριση των A/B/C mechanisms πραγματοποιήθηκε σε σταθερό validation subset 100 examples λόγω υπολογιστικού κόστους.

2.3 Πρωτόκολλο Αξιολόγησης και Αβεβαιότητα

Η αξιολόγηση πραγματοποιήθηκε με κοινό πειραματικό setup για όλες τις μεθόδους, ώστε να διασφαλιστεί δίκαιη σύγκριση. Συγκεκριμένα, όλες οι προσεγγίσεις εφαρμόστηκαν στα ίδια σύνολα δεδομένων και με τις ίδιες βασικές ρυθμίσεις. Οι μετρικές αξιολόγησης περιλαμβάνουν δείκτες ποιότητας, όπως το F1-score και την ακρίβεια (accuracy), δείκτες ασφάλειας, όπως το False Positive Rate (FPR) και το False Negative Rate (FNR), καθώς και ανάλυση αποχής μέσω καμπυλών coverage–risk. Επιπλέον, αξιολογείται και το υπολογιστικό κόστος μέσω μετρήσεων latency και throughput. Συνολικά, υλοποιήθηκαν τρεις διαφορετικές στρατηγικές λήψης απόφασης, οι μεθόδοι Direct Generation, Log-likelihood Scoring και Self-Consistency.

Παράλληλα, η αξιολόγηση του συστήματος περιλαμβάνει τη διαχείριση αβεβαιότητας μέσω της δυνατότητας αποχής (DEFER), καθώς και ανάλυση της σχέσης μεταξύ κάλυψης και σφάλματος. Ταυτόχρονα, εξετάζεται η συμπεριφορά του συστήματος σε σενάρια robustness με τροποποιημένα inputs, τα οποία προσομοιώνουν προσπάθειες αποφυγής moderation.

2.4 Δομημένη Έξοδος

Το σύστημα έχει σχεδιαστεί ώστε να παράγει έξοδο σε αυστηρά δομημένη μορφή JSON, σύμφωνα με προκαθορισμένο schema που περιλαμβάνει την τελική ετικέτα (label ∈ {TOXIC,

NON_TOXIC, DEFER}), την κατηγορία (category, π.χ. insult, hate, profanity), τον βαθμό εμπιστοσύνης (confidence ∈ [0,1]) και μια σύντομη αιτιολόγηση (short_rationale).

Δεδομένου ότι τα generative μοντέλα συχνά παράγουν μη έγκυρη ή μη πλήρη JSON έξοδο, εφαρμόζεται μηχανισμός validation και safe fallback. Ο μηχανισμός εξάγει JSON object από την έξοδο του μοντέλου όταν αυτό υπάρχει, ελέγχει την εγκυρότητα των υποχρεωτικών πεδίων, κανονικοποιεί απλές ασυνέπειες σε label και category, και επιστρέφει την ετικέτα DEFER όταν η έξοδος είναι μη έγκυρη ή μη ανακτήσιμη. Η διαδικασία αυτή είναι κρίσιμη για τη σταθερότητα του συστήματος, καθώς διασφαλίζει ότι όλες οι έξοδοι είναι έγκυρες και αξιοποιήσιμες.

3. Model, JSON Validation, and Decision Mechanisms

3.1 Παραγωγή Δομημένης Εξόδου από το Μοντέλο

Το σύστημα βασίζεται σε ένα generative LLM, το οποίο λειτουργεί ως “κριτής” (LLM-as-a-Judge). Για κάθε είσοδο (κειμενικό σχόλιο), το μοντέλο καλείται να επιστρέψει μια απόφαση σε αυστηρά καθορισμένη μορφή JSON. Η μορφή αυτή περιλαμβάνει τέσσερα βασικά πεδία. Το label για την τελική απόφαση (TOXIC, NON_TOXIC ή DEFER), το category για την κατηγορία τοξικότητας (π.χ. insult, hate, profanity), confidence όπου είναι ο βαθμός εμπιστοσύνης στο διάστημα [0,1] και το short_rationale, δηλαδή μια σύντομη αιτιολόγηση της απόφασης. Η χρήση JSON επιτρέπει την εύκολη ενσωμάτωση του συστήματος σε pipelines και αυξάνει τη διαφάνεια των αποφάσεων, καθώς παρέχει όχι μόνο το αποτέλεσμα αλλά και επιπλέον πληροφορία για την ερμηνεία του.

3.2 JSON Validation και Safe Fallback

Για να διασφαλιστεί η αξιοπιστία του συστήματος, εφαρμόζεται διαδικασία JSON validation και repair μετά την παραγωγή της εξόδου. Η διαδικασία περιλαμβάνει μια σειρά από 5 στάδια. Αρχικά, γίνεται εξαγωγή του JSON μέσω εντοπισμού του στο παραγόμενο κείμενο του μοντέλου. Έπειτα, γίνεται συντακτικός έλεγχος (Parsing), δηλαδή αν το JSON είναι έγκυρο (σωστά brackets, quotes κ.λπ.). Στη συνέχεια, γίνεται έλεγχος των πεδίων, αν το label ανήκει στο σύνολο {TOXIC, NON_TOXIC, DEFER}, το confidence είναι αριθμός στο [0,1] και τα υπόλοιπα πεδία δεν είναι κενά. Μετά, γίνεται περιορισμένη κανονικοποίηση απλών label/category ασυνεπειών, όπως διαφορετική κεφαλαιοποίηση ή κοντινές λεκτικές μορφές. Αν το JSON δεν μπορεί να γίνει parse, αν λείπουν υποχρεωτικά πεδία, αν το confidence δεν είναι αριθμητικό ή αν η τιμή είναι εκτός [0,1], το σύστημα επιστρέφει label = DEFER.

Table 1: *JSON Validation Errors & Handling*

Τύπος Σφάλματος	**Περιγραφή**	**Ενέργεια Συστήματος**
Missing Field	Λείπει ένα ή περισσότερα πεδία (label κτλ).	Προσπάθεια repair ή DEFER
Invalid Label	Το label δεν είναι έγκυρο.	DEFER

Invalid Confidence	Confidence εκτός [0,1].	Διόρθωση ή DEFER
Malformed JSON	Λάθος σύνταξη (quotes, brackets κτλ).	Repair
Extra Text	Κείμενο εκτός JSON.	Εξαγωγή JSON
Empty Output	Δεν επιστρέφεται αποτέλεσμα.	DEFER
Inconsistent Fields	Αντίφαση μεταξύ πεδίων.	DEFER

3.3 Decision Mechanisms

Η τελική απόφαση του συστήματος δεν βασίζεται μόνο στην έξοδο του μοντέλου, αλλά και στη στρατηγική που χρησιμοποιείται για την ερμηνεία της. Στην παρούσα εργασία εξετάζονται τρεις βασικοί μηχανισμοί. Πρώτον, το Direct Generation, όπου το μοντέλο παράγει μία μόνο απάντηση (deterministic decoding, temperature = 0). Η απόφαση λαμβάνεται απευθείας από το JSON. Τα πλεονεκτήματα σε αυτόν τον μηχανισμό είναι το χαμηλό υπολογιστικό κόστος που προσφέρει και η γρήγορη απόκρισή του, όμως είναι ευαίσθητο σε αβεβαιότητα και δεν λαμβάνει υπόψη εναλλακτικές εξηγήσεις.

Ο δεύτερος μηχανισμός είναι το Log-likelihood Scoring, όπου σε αυτή τη μέθοδο υπολογίζεται η πιθανότητα (log-likelihood) για κάθε πιθανή ετικέτα. Η απόφαση λαμβάνεται ως η ετικέτα με τη μεγαλύτερη πιθανότητα ή εφαρμόζεται threshold για DEFER. Εδώ, ο μηχανισμός παρουσιάζει καλή διαχωριστική ικανότητα (ranking) και επιτρέπει ρύθμιση thresholds για DEFER, όμως έχει υψηλότερο False Positive Rate και δεν αξιοποιεί πλήρως τη generative φύση του μοντέλου. Τέλος, έχουμε τον μηχανισμό Self-Consistency, στον οποίο το μοντέλο εκτελείται πολλαπλές φορές με sampling και παράγει διαφορετικές απαντήσεις. Η τελική απόφαση λαμβάνεται μέσω majority voting. Επιπλέον, αν η συμφωνία είναι χαμηλή DEFER, το μοντέλο παίρνει πιο σταθερές και αξιόπιστες αποφάσεις και το risk είναι μειωμένο, από την άλλη όμως αυτή η μέθοδος έχει υψηλό υπολογιστικό κόστος και μικρότερο coverage.

Table 2. *Decision rules for final prediction.*

Μέθοδος	**Υπολογιστικό Κόστος**	**Σταθερότητα**	**Risk**	**Coverage**	**Περιγραφή**
Direct Generation	Χαμηλό	Μέτρια	Μέτριο	Υψηλό	Μία απάντηση από το μοντέλο
Log-likelihood Scoring	Μέτριο	Μέτρια	Υψηλό	Μέτριο	Απόφαση βάσει πιθανότητας
Self-Consistency	Υψηλό	Υψηλή	Χαμηλό	Χαμηλό	Πολλαπλές απαντήσεις + voting

3.4 Μηχανισμός Λήψης Τελικής Απόφασης

Ο τελικός μηχανισμός συνδυάζει το confidence threshold, το agreement για Self-Consistency και το JSON validity. Η λογική απόφασης είναι η εξής: αν το JSON είναι invalid, το σύστημα επιστρέφει DEFER. Αν το confidence είναι μικρότερο από το threshold, επιστρέφει DEFER. Αν το disagreement είναι υψηλό, επιστρέφει DEFER. Σε διαφορετική περίπτωση, επιστρέφει TOXIC ή NON_TOXIC.

3.5 Σχέση με Αβεβαιότητα και Ασφάλεια

Η εισαγωγή του DEFER μετατρέπει το σύστημα από κλασικό classifier σε risk-aware system. Αντί να ελαχιστοποιείται μόνο το error, το σύστημα αποφεύγει λάθος αποφάσεις, μεταφέρει αβέβαιες περιπτώσεις σε άνθρωπο ή επόμενο στάδιο και υποστηρίζει καλύτερο έλεγχο του coverage–risk trade-off μέσω abstention.

4. Results and Coverage–Risk Analysis

Η αξιολόγηση έγινε στο validation subset με σκοπό να συγκριθούν τα τρία decision mechanisms, δηλαδή το Direct Generation, το Log-likelihood Scoring και το Self-Consistency. Η σύγκριση βασίστηκε σε κοινά evaluation examples, ώστε τα αποτελέσματα να είναι όσο γίνεται πιο δίκαια. Τα βασικά metrics που χρησιμοποιήθηκαν ήταν F1 score για την κλάση TOXIC, AUROC, AUPRC, coverage, risk, καθώς και τα metrics που σχετίζονται με το safety όπως FPR και FNR.

Table 3. *Comparison of the three decision mechanisms on the validation subset.*

Method	**F1 Toxic**	**AUROC**	**AUPRC**	**Coverage**	**Risk**	**FPR**	**FNR**
Direct Generation	0.835	0.804	0.776	0.78	0.192	0.265	0.136
Log-likelihood Scoring	0.825	0.836	0.835	0.70	0.243	0.500	0.091
Self-Consistency	0.875	0.790	0.772	0.67	0.149	0.214	0.103

Τα FPR και FNR αναφέρονται στις non-deferred αποφάσεις, δηλαδή μόνο στις περιπτώσεις όπου το σύστημα δεν επέλεξε DEFER.

Από τα αποτελέσματα φαίνεται ότι το Self-Consistency πέτυχε το καλύτερο F1 Toxic score με τιμή 0.875, καθώς και το χαμηλότερο risk με τιμή 0.149. Αυτό δείχνει ότι η χρήση πολλαπλών sampled outputs και majority voting μπορεί να βελτιώσει την ποιότητα των αποφάσεων στις

περιπτώσεις όπου το σύστημα δίνει τελική απάντηση. Ωστόσο, αυτή η βελτίωση έρχεται με κόστος το χαμηλότερο coverage. Συγκεκριμένα, το Self-Consistency κάλυψε το 67% των παραδειγμάτων, ενώ τα υπόλοιπα έγιναν DEFER λόγω χαμηλού agreement ή αυξημένης αβεβαιότητας.

Το Direct Generation είχε το υψηλότερο coverage με τιμή 0.78, άρα παρήγαγε τελική απόφαση σε περισσότερα examples. Το F1 Toxic score ήταν επίσης ικανοποιητικό, με τιμή 0.835. Παρόλα αυτά, το risk ήταν υψηλότερο από το Self-Consistency. Αυτό δείχνει ότι η deterministic απάντηση του μοντέλου είναι πρακτική και γρήγορη, αλλά λιγότερο προσεκτική σε αβέβαιες περιπτώσεις.

Το Log-likelihood Scoring είχε τα καλύτερα ranking metrics, με AUROC 0.836 και AUPRC 0.835. Αυτό δείχνει ότι οι log-likelihood scores μπορούν να διαχωρίσουν αρκετά καλά τις περιπτώσεις TOXIC και NON_TOXIC σε επίπεδο score ranking. Παρ' όλα αυτά, είχε το υψηλότερο risk, με τιμή 0.243, και το υψηλότερο FPR, με τιμή 0.500. Αυτό σημαίνει ότι σε αρκετές περιπτώσεις NON_TOXIC το σύστημα έδωσε λανθασμένα απόφαση TOXIC. Επομένως, η μέθοδος αυτή είναι χρήσιμη για scoring και threshold analysis, όμως δεν ήταν η καλύτερη επιλογή ως τελικό operating point για ασφαλές moderation.

Η ανάλυση coverage–risk χρησιμοποιήθηκε για να εξεταστεί το trade-off ανάμεσα στο πόσα παραδείγματα αποφασίζει το σύστημα και πόσο συχνά κάνει λάθος στις non-deferred αποφάσεις. Όσο αυξάνεται το threshold για confidence ή agreement, το σύστημα κάνει DEFER σε περισσότερες αβέβαιες περιπτώσεις. Αυτό μειώνει το coverage, αλλά συνήθως μειώνει και το risk. Η λογική αυτή είναι σημαντική για moderation, επειδή σε αβέβαιες ή borderline περιπτώσεις είναι προτιμότερο το σύστημα να αποφεύγει μια λανθασμένη αυτόματη απόφαση.

Το Figure 1 παρουσιάζει την coverage–risk curve. Η καμπύλη δείχνει ότι δεν υπάρχει ένα μοναδικό τέλειο σημείο. Αν ο στόχος είναι μεγαλύτερη αυτοματοποίηση, τότε μπορεί να επιλεγεί υψηλότερο coverage με αποδοχή μεγαλύτερου risk. Αν ο στόχος είναι πιο ασφαλές moderation, τότε είναι προτιμότερο χαμηλότερο coverage και περισσότερα DEFER decisions.

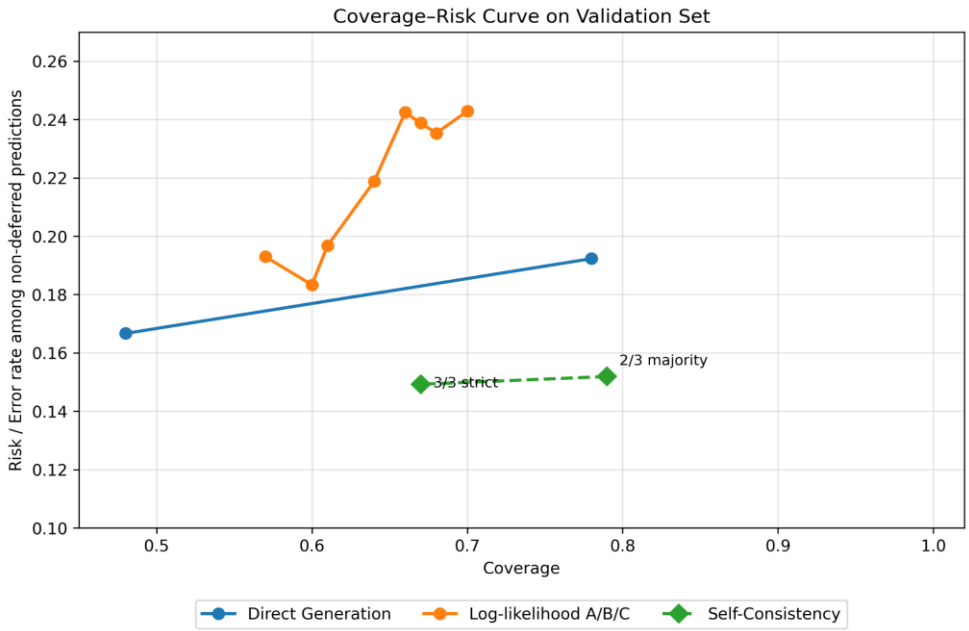

Figure 1. *Coverage–risk curve comparing Direct Generation, Log-likelihood Scoring, and Self-Consistency on the validation subset.*

Με βάση τα αποτελέσματα, το Self-Consistency είναι η πιο κατάλληλη επιλογή όταν η προτεραιότητα είναι η μείωση του risk και η αποφυγή λανθασμένων automatic moderation decisions. Αντίθετα, το Direct Generation είναι πιο πρακτικό όταν χρειάζεται μεγαλύτερο coverage και χαμηλότερο runtime cost. Το Log-likelihood Scoring είναι χρήσιμο για score-based analysis και threshold selection, αλλά στην παρούσα αξιολόγηση δεν έδωσε το καλύτερο τελικό risk.

Συνολικά, τα αποτελέσματα δείχνουν ότι το DEFER mechanism είναι απαραίτητο σε ένα LLM-as-a-Judge moderation system. Χωρίς abstention, το μοντέλο θα αναγκαζόταν να αποφασίζει ακόμα και σε αβέβαιες περιπτώσεις. Με το DEFER, το σύστημα μπορεί να ελέγχει καλύτερα το trade-off ανάμεσα σε coverage και risk, κάτι που είναι ιδιαίτερα σημαντικό για safety-critical moderation tasks.

5. Robustness and Mitigation

5.1 Στόχος του Robustness Evaluation

Η αξιολόγηση robustness εξετάζει αν το σύστημα moderation παραμένει αξιόπιστο όταν το ίδιο σημασιολογικό μήνυμα εμφανίζεται με μικρές, σκόπιμες αλλοιώσεις. Σε πραγματικά online περιβάλλοντα οι χρήστες συχνά προσπαθούν να παρακάμψουν φίλτρα τοξικότητας με ανορθογραφίες, επιπλέον σύμβολα, διαχωρισμό χαρακτήρων ή leetspeak. Για αυτόν τον λόγο, το project δεν περιορίζεται μόνο στην απόδοση πάνω σε καθαρά παραδείγματα του Civil Comments, αλλά δοκιμάζει και adversarial εκδοχές των ίδιων σχολίων. Η ανάλυση πραγματοποιήθηκε σε ένα μικρό αλλά ισορροπημένο subset είκοσι παραδειγμάτων, με δέκα TOXIC και δέκα NON_TOXIC σχόλια, ώστε οι αλλαγές σε FPR και FNR να είναι εύκολα ερμηνεύσιμες.

Οι επιθέσεις υλοποιούνται στο αρχείο src/robustness_attacks.py και εφαρμόζονται πριν από το Direct Generation pipeline. Συγκεκριμένα, χρησιμοποιούνται πέντε τύποι perturbations: τυχαίος θόρυβος χαρακτήρα (typo_noise), επανάληψη φωνηέντων (character_repetition), εισαγωγή κενών ανάμεσα στα γράμματα σημαντικών λέξεων (spacing), αντικατάσταση γραμμάτων με αριθμούς ή σύμβολα (leetspeak), και benign quoting, όπου ένα τοξικό σχόλιο τοποθετείται μέσα σε επεξηγηματικό/αναλυτικό πλαίσιο. Το τελευταίο είναι ιδιαίτερα σημαντικό επειδή δεν αποτελεί απλή ορθογραφική παραλλαγή αλλά ελέγχει αν το μοντέλο μπορεί να ξεχωρίσει πραγματική τοξικότητα από αναφορά σε τοξική φράση.

5.2 Αποτελέσματα πριν από το Mitigation

Στο καθαρό condition το Direct Generation είχε F1 Toxic 0.933, risk 0.067 και coverage 0.75. Αυτό δείχνει ότι, όταν το κείμενο δίνεται χωρίς τεχνητές αλλοιώσεις, το σύστημα μπορεί να παράγει αρκετά αξιόπιστες αποφάσεις, αν και το DEFER παραμένει ενεργό για περίπου το ένα τέταρτο των περιπτώσεων. Μετά την εφαρμογή των attacks, η συμπεριφορά γίνεται πιο ανομοιόμορφη. Το typo_noise έχει μικρή επίδραση, με F1 0.947 και risk 0.063, επειδή μια

μεμονωμένη εισαγωγή συμβόλου σπάνια αλλάζει τη συνολική σημασία του σχολίου. Αντίθετα, το leetspeak είναι η πιο επικίνδυνη επίθεση: το F1 πέφτει σε 0.690, το risk αυξάνεται σε 0.474 και το FPR φτάνει στο 1.000 στις non-deferred αποφάσεις.

Η υψηλή τιμή FPR στο leetspeak δείχνει ότι το μοντέλο γίνεται υπερβολικά ευαίσθητο όταν βλέπει obfuscated κείμενο. Αντί να αναγνωρίζει με σταθερό τρόπο τις αρχικές λέξεις, μπορεί να ερμηνεύει τα σύμβολα ως ένδειξη ύποπτης συμπεριφοράς και να ταξινομεί non-toxic σχόλια ως TOXIC. Παρόμοια τάση εμφανίζεται και στις επιθέσεις spacing και character_repetition, όπου οι toxic λέξεις δεν εξαφανίζονται εντελώς αλλά γίνονται πιο δύσκολες για το prompt-based reasoning. Το benign quoting είναι πιο ελεγχόμενο αφού το F1 παραμένει 0.875, όμως το defer_rate ανεβαίνει σε 0.25, κάτι που είναι επιθυμητό όταν το context κάνει την απόφαση αβέβαιη.

Table 4: *Robustness performance before and after normalization mitigation*.

Attack	F1 πριν	F1 μετά	Risk πριν	Risk μετά	Coverage μετά
Leetspeak	0.690	0.824	0.474	0.176	0.850
Character repetition	0.818	0.842	0.222	0.188	0.800
Spacing	0.857	0.800	0.188	0.267	0.750
Benign quoting	0.875	1.000	0.133	0.000	0.500
Typo noise	0.947	0.842	0.062	0.188	0.800

5.3 Mitigation μέσω Κανονικοποίησης Κειμένου

Το mitigation υλοποιείται στο αρχείο src/mitigation.py με τη συνάρτηση normalize_text(). Η συνάρτηση λειτουργεί ως preprocessing layer πριν από την κλήση του LLM και στοχεύει σε απλές, ερμηνεύσιμες διορθώσεις, δηλαδή μετατροπή του κειμένου σε lowercase, αντιστροφή συνηθισμένων leetspeak χαρακτήρων όπως 4→a, 3→e, 1→i, 0→o, $→s και 7→t, συμπίεση υπερβολικών επαναλήψεων χαρακτήρων, αποκατάσταση spaced toxic λέξεων όπως i d i o t ή s t u p i d, και τελική κανονικοποίηση των κενών. Η επιλογή rule-based mitigation είναι σκόπιμη καθώς δεν προσθέτει νέο μοντέλο, είναι γρήγορη, αναπαράξιμη και επιτρέπει να καταλάβουμε ακριβώς ποια μορφή αλλοίωσης διορθώνεται.

Μετά την κανονικοποίηση, η μεγαλύτερη βελτίωση εμφανίζεται στο leetspeak. Το F1 ανεβαίνει από 0.690 σε 0.824, ενώ το risk μειώνεται από 0.474 σε 0.176. Αυτό επιβεβαιώνει ότι μεγάλο μέρος της αποτυχίας οφειλόταν στην επιφανειακή μορφή των χαρακτήρων και όχι σε πραγματική αδυναμία κατανόησης του νοήματος. Βελτίωση παρατηρείται επίσης στο character_repetition, όπου το F1 αυξάνεται από 0.818 σε 0.842 και το risk μειώνεται από 0.222 σε 0.188. Στο benign quoting το mitigation οδηγεί σε F1 1.000 και risk 0.000 στις non-deferred αποφάσεις, αλλά αυτό επιτυγχάνεται με coverage 0.50, δηλαδή με περισσότερες περιπτώσεις DEFER.

Τα αποτελέσματα δείχνουν επίσης τα όρια της απλής κανονικοποίησης. Στο spacing attack το F1 μειώνεται από 0.857 σε 0.800 και το risk αυξάνεται από 0.188 σε 0.267, ενώ στο typo_noise το mitigation επίσης χειροτερεύει την απόδοση σε σχέση με το attacked condition. Αυτό συμβαίνει επειδή ένα γενικό preprocessing βήμα μπορεί να αλλάξει λεπτές ενδείξεις του αρχικού κειμένου ή να δημιουργήσει ψευδή σιγουριά στο μοντέλο. Επομένως, η κανονικοποίηση δεν πρέπει να θεωρείται πλήρης λύση, αλλά ένα πρώτο φίλτρο που μειώνει συγκεκριμένες μορφές evasion.

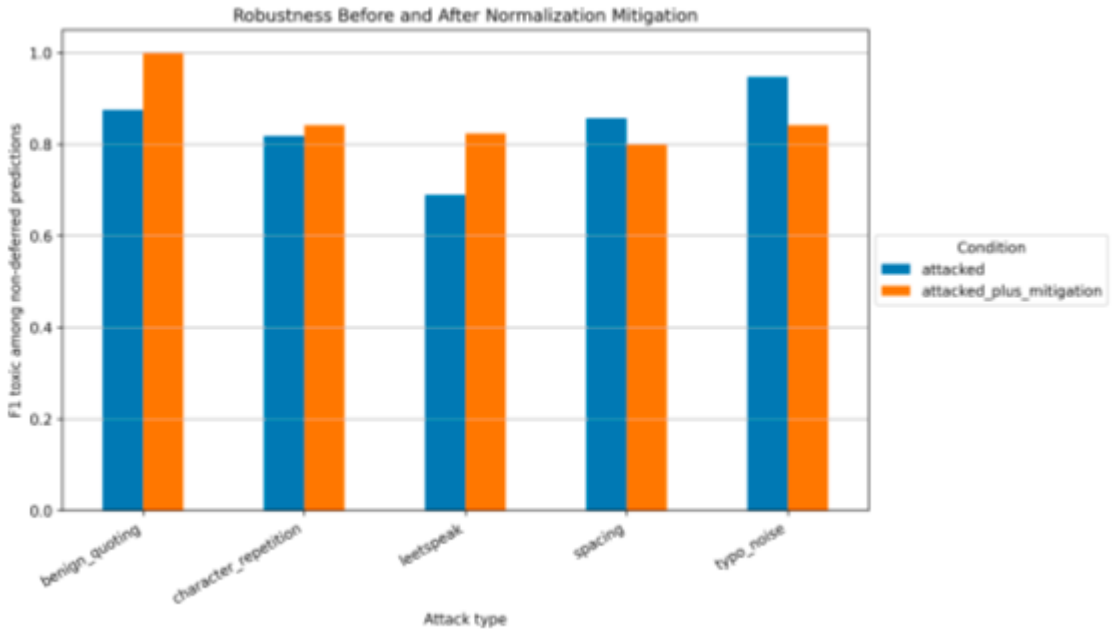

Figure 2. F1 Toxic score under adversarial attacks, before and after mitigation.

5.4 Στρατηγική Ασφαλούς Χρήσης

Η βασική στρατηγική mitigation του project είναι πολυεπίπεδη. Πρώτον, το input καθαρίζεται με deterministic normalization, ώστε οι πιο συνηθισμένες obfuscation τεχνικές να μετατρέπονται σε πιο αναγνώσιμη μορφή. Δεύτερον, η έξοδος του μοντέλου περνά από αυστηρό JSON validation. Αν δεν εντοπιστεί έγκυρο JSON object, αν λείπουν υποχρεωτικά πεδία, αν το confidence είναι εκτός [0,1] ή αν το label είναι αμφίσημο, το σύστημα επιστρέφει DEFER αντί να παράγει αυθαίρετη απόφαση. Τρίτον, για περιπτώσεις υψηλού ρίσκου μπορεί να χρησιμοποιηθεί Self-Consistency, το οποίο στο validation subset πέτυχε χαμηλότερο risk από το Direct Generation, με κόστος όμως μεγαλύτερο latency και μικρότερο coverage.

Η χρήση του DEFER είναι κρίσιμη για robustness. Σε moderation συστήματα, ένα λάθος TOXIC μπορεί να λογοκρίνει μη προβληματικό περιεχόμενο, ενώ ένα λάθος NON_TOXIC μπορεί να αφήσει επιβλαβές περιεχόμενο ενεργό. Αν το μοντέλο αντιμετωπίζει obfuscated, quoted ή context-dependent σχόλιο, η ασφαλέστερη συμπεριφορά είναι να μειώσει το coverage και να ζητήσει ανθρώπινο έλεγχο. Με αυτόν τον τρόπο το σύστημα γίνεται risk-aware αφού δεν μετρά μόνο πόσες αποφάσεις παίρνει, αλλά και πόσο αξιόπιστες είναι οι αποφάσεις που δεν κάνει defer.

5.5 Περιορισμοί και Μελλοντικές Βελτιώσεις

Η αξιολόγηση robustness είναι χρήσιμη, αλλά παραμένει περιορισμένη επειδή βασίζεται σε είκοσι παραδείγματα. Για πιο ισχυρά συμπεράσματα θα χρειαζόταν μεγαλύτερο adversarial test set, περισσότερα είδη perturbations, και ξεχωριστή ανάλυση ανά κατηγορία τοξικότητας. Επιπλέον, οι κανόνες κανονικοποίησης καλύπτουν μόνο συγκεκριμένες αγγλικές λέξεις και απλές μορφές leetspeak. Σε πραγματική παραγωγική χρήση θα έπρεπε να επεκταθούν με multilingual patterns, fuzzy matching, character-level similarity, και monitoring των νέων evasion patterns που εμφανίζονται δυναμικά.

Συνολικά, το robustness experiment δείχνει ότι ένα μικρό generative LLM μπορεί να λειτουργήσει ως moderation judge, αλλά χρειάζεται προστατευτικά επίπεδα γύρω από το ίδιο το μοντέλο. Το preprocessing βελτιώνει σημαντικά συγκεκριμένες επιθέσεις όπως το leetspeak, το JSON validator αποτρέπει μη δομημένες ή ασαφείς εξόδους, και το DEFER μειώνει την πιθανότητα επικίνδυνων automatic decisions. Επομένως, η τελική αρχιτεκτονική δεν αντιμετωπίζει το LLM ως απόλυτο classifier, αλλά ως ένα component μέσα σε ένα πιο προσεκτικό pipeline αξιοπιστίας και ασφάλειας.

6. Failure Analysis, Ethics, and Conclusion

6.1 Failure Analysis

Το Failure Analysis έδειξε ότι το σύστημα Gemma-Based LLM-as-a-Judge λειτουργεί αρκετά καλά για toxicity moderation, αλλά δεν είναι σταθερό σε όλες τις περιπτώσεις. Η απόδοση του συστήματος μειώνεται κυρίως όταν το text είναι ασαφές, το περιεχόμενο του text είναι παραμορφωμένο ή χρειάζεται καλύτερη κατανόηση του context. Το toxicity moderation δεν είναι απλά αναζήτηση συγκεκριμένων λέξεων αλλά το μοντέλο πρέπει να καταλάβει αν ένα σχόλιο είναι πραγματικά harmful ή αν απλώς περιέχει λέξεις που φαίνονται toxic αλλά δεν είναι αν λάβεις υπόψη όλο το context.

Στο project είχαμε 3 decision mechanisms, το Self-Consistency είχε την καλύτερη ποιότητα στις non-deferred προβλέψεις, συγκεκριμένα είχε το υψηλότερο toxic-class F1 0.875 και είχε επίσης και το χαμηλότερο risk 0.149 συνεπώς τα παραπάνω δείχνουν ότι το majority voting μπορεί να κάνει το σύστημα πιο αξιόπιστο και ακριβές. Αντιθέτως, αφού το Self-Consistency χρειάζεται πολλαπλά model outputs για κάθε input με επακόλουθο ένα υψηλό μέσο latency περίπου 14.8 δευτερόλεπτα, καθιστώντας το μη κατάλληλο για real-time moderation. Το Direct Generation είχε 0.78 coverage, 0.22 defer rate και 0.835 F1 δηλαδή πιο ισορροπημένο, αλλά είχε μεγαλύτερο risk 0.192, και χαμηλότερο JSON validity 0.83, αυτό σημαίνει ότι δίνει χρήσιμες απαντήσεις αλλά το output δεν ακολουθεί σωστά το strict JSON schema. Το Log-likelihood Scoring ήταν το method που ήταν πιο γρήγορο συγκριτικά με τα άλλα 2, είχε μέσο latency 437ms, είχε τέλειο JSON validity, αυτό συμβαίνει επειδή βαθμολογεί προκαθορισμένα label completions, αλλά είχε το υψηλότερο false positive rate 0.5 και το υψηλότερο risk 0.243, άρα συνοπτικά ήταν αυστηρότερο και έκανε classify και ταξινόμησε αρκετά non-toxic σχόλια σαν toxic.

Σε τέτοιου είδους models το σημαντικότερο κομμάτι είναι η ελαχιστοποίηση των false negatives, δηλαδή των περιπτώσεων όπου toxic text έγινε classify σαν non-toxic, σε ένα moderation system αυτά του είδους λάθη είναι επικίνδυνα καθώς δεν εντοπίζονται από το model και ίσως προκύψουν ζητήματα αξιοπιστίας. Επίσης, τα false positives είναι σημαντικά, επειδή non-toxic comments μπορεί να ταξινομηθούν λανθασμένα ως toxic, οδηγώντας σε άδικες moderation decisions ή άσκοπο μπλοκάρισμα harmless content. Τα JSON failures δείχνουν ότι το strict JSON validation, η περιορισμένη κανονικοποίηση label/category, και το fallback σε DEFER είναι απαραίτητα ώστε το σύστημα να είναι αξιόπιστο.

Τα robustness attacks έδειξαν ότι απλές αλλαγές στο input μπορούν να μειώσουν σημαντικά την απόδοση του μοντέλου, αυτό παρατηρήθηκε εντονότερα στο leetspeak όπου το F1-Score, έπεσε στο 0.69 και το risk ανέβηκε στο 0.474 πριν από το mitigation. Μετά το normalization/deobfuscation mitigation, το F1-Score βελτιώθηκε στο 0.824 και το risk μειώθηκε στο 0.176. Αντίθετα το mitigation δεν βοήθησε όλες τις περιπτώσεις καθώς σε spacing attacks και typo noise αλλοίωσε χρήσιμες πληροφορίες του αρχικού input. Συμπερασματικά το σύστημα είναι χρήσιμο σαν research prototype αλλά χρειάζεται DEFER validation και ανθρώπινη εποπτεία για πιο ασφαλή χρήση.

6.2 Ethics

Το toxicity moderation έχει σημαντικά ηθικά ζητήματα, επειδή και τα δύο βασικά είδη λαθών μπορούν να προκαλέσουν πρόβλημα. Ένα false negative επιτρέπει σε toxic ή harmful content να παραμείνει ορατό, ενώ ένα false positive μπορεί να μπλοκάρει ένα non-toxic comment.

Ένα σημαντικό ethical concern είναι το bias. Το Civil Comments dataset περιλαμβάνει online comments και μπορεί να έχει συσχετίσεις ανάμεσα σε identity-related terms και toxic labels. Για παράδειγμα, αναφορές σε φύλο, θρησκεία, εθνικότητα, sexual orientation ή disability μπορεί να εμφανίζονται συχνότερα σε toxic contexts. Αυτό μπορεί να οδηγήσει το μοντέλο σε unfair false positives απέναντι σε συγκεκριμένες ομάδες. Για αυτόν τον λόγο, ένα πραγματικό moderation system δεν πρέπει να αξιολογείται μόνο με συνολικά metrics όπως F1, AUROC και AUPRC, αλλά και με subgroup evaluation.

Ο μηχανισμός DEFER είναι σημαντικός από ethical perspective, επειδή επιτρέπει στο σύστημα να μην αποφασίζει όταν υπάρχει υψηλή αβεβαιότητα. Αντί το μοντέλο να παίρνει μια πιθανώς λανθασμένη απόφαση, μπορεί να στείλει την περίπτωση για ανθρώπινο έλεγχο.

Επιπλέον, το project χρησιμοποίησε benchmark data μόνο για evaluation και threshold selection, χωρίς fine-tuning και χωρίς συλλογή private user data. Αυτό μειώνει το privacy risk. Συνολικά, το σύστημα πρέπει να θεωρηθεί ως decision-support tool και όχι ως πλήρως αυτόνομη λύση moderation.

6.3 Conclusion

Σε αυτό το project υλοποιήθηκε και αξιολογήθηκε ένα Gemma-based LLM-as-a-Judge για toxicity moderation. Το σύστημα παρήγαγε structured outputs με strict JSON schema, το οποίο περιλάμβανε label, category, confidence score και short rationale. Συγκρίθηκαν τρία decision mechanisms: Direct Generation, Log-likelihood Scoring και Self-Consistency, ενώ

αξιολογήθηκαν επίσης το DEFER, το coverage-risk trade-off, τα robustness attacks, το mitigation και το latency.

Τα αποτελέσματα έδειξαν ότι κάθε method έχει διαφορετικά πλεονεκτήματα και μειονεκτήματα. Το Self-Consistency είχε την καλύτερη ποιότητα και το χαμηλότερο ρίσκο, αλλά ήταν το πιο αργό. Το Log-likelihood Scoring ήταν το πιο γρήγορο και είχε τέλειο JSON validity, αλλά είχε υψηλό false positive rate. Το Direct Generation ήταν μια πιο πρακτική ενδιάμεση λύση, αλλά είχε περισσότερα προβλήματα σε JSON validity και robustness.

Συνολικά, το project δείχνει ότι ένα μικρό quantized generative LLM μπορεί να χρησιμοποιηθεί για toxicity moderation, αρκεί να συνδυάζεται με strict validation, DEFER, uncertainty handling και robustness testing. Παρ' όλα αυτά, το σύστημα παραμένει research prototype και όχι έτοιμη production λύση. Μελλοντική εργασία θα πρέπει να περιλαμβάνει μεγαλύτερο evaluation set, καλύτερο calibration, subgroup fairness analysis, πιο ισχυρό context handling και human-in-the-loop workflow για high-risk ή deferred cases.

References

Borkan, D., Dixon, L., Sorensen, J., Thain, N., & Vasserman, L. (2019). Nuanced metrics for measuring unintended bias with real data for text classification. In *Companion Proceedings of The 2019 World Wide Web Conference* (pp. 491–500). Association for Computing Machinery. https://doi.org/10.1145/3308560.3317593

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). *QLoRA: Efficient finetuning of quantized LLMs*. Advances in Neural Information Processing Systems, *36*, 10088–10115. https://arxiv.org/abs/2305.14314

Gemma Team. (2024). *Gemma 2: Improving open language models at a practical size*. arXiv. https://doi.org/10.48550/arXiv.2408.00118

Google. (2024). *google/gemma-2-2b-it* [Model card]. Hugging Face. https://huggingface.co/google/gemma-2-2b-it

Google. (n.d.). *google/civil_comments* [Data set]. Hugging Face. Retrieved May 5, 2026, from https://huggingface.co/datasets/google/civil_comments

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning* (pp. 1321–1330). PMLR. https://proceedings.mlr.press/v70/guo17a.html

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Lhoest, Q., Villanova del Moral, A., Jernite, Y., Thakur, A., von Platen, P., Patil, S., Chaumond, J., Drame, M., Plu, J., Tunstall, L., Davison, J., Šaško, M., Chhablani, G., Malik, B., Brandeis, S., Le Scao, T., Sanh, V., Xu, C., Patry, N., McMillan-Major, A., Schmid, P., Gugger, S., Delangue, C., Matussière, T., Debut, L., Bekman, S., Cistac, P., Goehringer, T., Mustar, V., Lagunas, F., Rush, A. M., & Wolf, T. (2021). Datasets: A community library for natural language processing. In *Proceedings of the 2021 Conference on Empirical Methods*

in Natural Language Processing: System Demonstrations (pp. 175–184). Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.emnlp-demo.21

McKinney, W. (2010). Data structures for statistical computing in Python. In S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems, 32*, 8024–8035. https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://www.jmlr.org/papers/v12/pedregosa11a.html

Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E., Narang, S., Chowdhery, A., & Zhou, D. (2023). Self-consistency improves chain of thought reasoning in language models. *International Conference on Learning Representations*. https://openreview.net/forum?id=1PL1NIMMrw

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., Drame, M., Lhoest, Q., & Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (pp. 38–45). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-demos.6

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems, 36*. https://arxiv.org/abs/2306.05685